Avaliação de um leitor automático de PDF para português brasileiro

Resumo — Este trabalho avalia a extração de texto de documentos em PDF para fins de leitura em voz alta. São considerados três tipos de documento: romance comercial, divulgação científica e artigo em duas colunas. A métrica adotada é a taxa de erro de caractere em relação ao texto de origem.

1. Introdução

A conversão de PDF para texto contínuo é tratada com frequência como um problema resolvido, o que não corresponde à prática [1]. Documentos diagramados em duas colunas, com cabeçalho corrente e notas de rodapé, produzem sequências de linhas cuja ordem de leitura não é a ordem em que aparecem no arquivo [2], [3].

Silva et al. (2020) demonstraram que a taxa de erro cresce com o número de elementos flutuantes na página. O presente trabalho reproduz esse resultado e acrescenta uma análise por tipo de defeito.

2. Método

Foram gerados documentos sintéticos a partir de um texto de origem conhecido, o que permite medir o erro sem anotação manual. Cada documento recebeu uma diagramação distinta, mantendo o conteúdo constante.

A extração foi executada no próprio dispositivo de destino, um aparelho Android, com a mesma biblioteca usada em produção, de modo que o resultado medido é o resultado entregue ao usuário.

3. Resultados

A taxa de erro de caractere ficou abaixo de 1% para o romance e para a divulgação científica, e acima desse valor para o artigo em duas colunas, concentrada nas transições entre colunas.

O corpus é composto por documentos gerados automaticamente, de modo que o texto de origem permanece disponível para comparação. Essa escolha elimina a necessidade de anotação humana e torna o experimento reprodutível por terceiros, bastando executar o gerador.

Cada documento foi diagramado com os elementos que a literatura aponta como causadores de erro: cabeçalho corrente alternando entre páginas pares e ímpares, numeração de página, capitular no início de capítulo, quebra de cena sinalizada por asteriscos e hifenização no fim de linha.

A comparação entre o texto extraído e o texto de origem foi feita bloco a bloco, com alinhamento por distância de edição. Um bloco é considerado perdido quando não encontra correspondente com similaridade superior a oitenta por cento.

4. Discussão

Os erros observados concentram-se em três categorias. A primeira é a fusão de blocos distintos num único parágrafo, que ocorre quando o cabeçalho corrente não é removido antes da montagem e acaba inserido entre duas linhas de texto corrido.

A segunda categoria é a perda da primeira letra de um capítulo, causada pela capitular, que o extrator interpreta como um elemento gráfico independente por estar em corpo muito maior que o restante da linha.

A terceira é a inversão da ordem de leitura em documentos de duas colunas, na qual linhas da coluna da direita são intercaladas com linhas da coluna da esquerda, produzindo um texto sintaticamente impossível.

Nenhuma das três categorias exige aprendizado de máquina para ser corrigida. Todas dependem de informação geométrica já disponível no arquivo, desde que o extrator a preserve em vez de descartá-la ao concatenar as linhas.

5. Conclusão

A extração de texto para leitura em voz alta exige critérios mais rigorosos do que a extração para indexação. Um erro que passa despercebido numa busca textual torna-se imediatamente audível quando o texto é pronunciado, e por isso a métrica adotada penaliza igualmente supressões e inserções.

Referências

[1] A. Pereira, “Extração de texto em documentos digitalizados”, Revista Brasileira de Computação, v. 12, n. 3, p. 45-61, 2019.

[2] M. Souza e R. Lima, “Ordem de leitura em documentos multicoluna”, Anais do Simpósio de Documentos Digitais, p. 112-120, 2021.

[3] J. Silva, C. Costa e F. Dias, “Layout analysis revisited”, Journal of Document Engineering, v. 8, p. 1-17, 2020.